CS307 Project1 报告（Task1-Task3）

一、项目基本信息

- 课程：CS307 Database
- 学期：Spring 2026
- 项目：Project 1（Airline Ticket Database）
- 数据来源：课程提供的 `region.csv`、`airline.csv`、`airport.csv`、`passenger.csv`、`tickets.csv`

1.1 小组成员与分工

- 张埕瑞：Task1（E-R 分析与绘制）、Task2（关系模型与 DDL）、Task3.1（导入脚本）、Task3.2（准确性检查 SQL）Task3.3（高级优化实验）
- 雷誉：

1.2 报告范围

本报告覆盖 Task1、Task2、Task3（含 3.1/3.2/3.3），不包含 Task4 的 CRUD 功能实现细节。记得写后面的

二、项目需求与数据特点

根据课程 PDF（`CS307-spring26-project1.pdf`）的 Task1-Task3 要求，本项目的核心目标为：

1. 基于给定 CSV 数据完成 E-R 设计并形成规范图示。
2. 使用 PostgreSQL 设计并实现关系数据库结构，满足规范化与约束要求。
3. 完成数据导入、准确性检查 SQL 准备与高级性能实验。

2.1 原始数据主要问题

- `tickets.csv` 同时包含静态航线信息与动态班次库存价格，冗余严重。
- `arrival_time` 存在 跨天信息，需要拆分到 `arrival_day_offset`。
- 地区名称在不同 CSV 中有别名（如 `Hong Kong SAR of China`、`DRAGON`）。
- `region.csv` 存在重复与空 code。
- `airport.csv` 存在个别 `iata_code = null` 字符串记录。
- 具体内容： 1.tickets.csv 里有 330 行引用了机场主数据里不存在的代码，分别是 JGS、LLB、YZY；代表行见 tickets.csv:11247、tickets.csv:20097、tickets.csv:34627。导致这些航班记录无法和 airport.csv 建立有效关联。 2.airport.csv:177 里有一条机场记录的 iata_code 直接写成了 null。 3.airline.csv:18、airline.csv:19、airline.csv:52 这几类记录的 region 值不能在 region.csv 里直接匹配到，具体是 Hong Kong SAR of China、DRAGON、Republic of Korea。 4.region.csv:35、region.csv:114、region.csv:103、region.csv:254 存在重复地区名，分别是 India 和 Palestine；另外还有 19 条 code 为空的记录，例如 region.csv:33 和 region.csv:116。如果按当前 schema 直接导入，空值需要先处理成 NULL。

2.2 设计思路

- 将航班数据拆成两层：
  - `flight_route`（静态航线）
  - `flight_instance`（按日期实例）

- 将机场基础信息与扩展地理/时区信息拆分：
  - `airport`
  - `airport_info`
- 统一地区、代码等字段规范化，保障后续查询性能与可维护性。

三、Task1：E-R 图设计（20%）

3.1 使用工具

- 绘图工具：draw.io

3.2 Task1 E-R 图

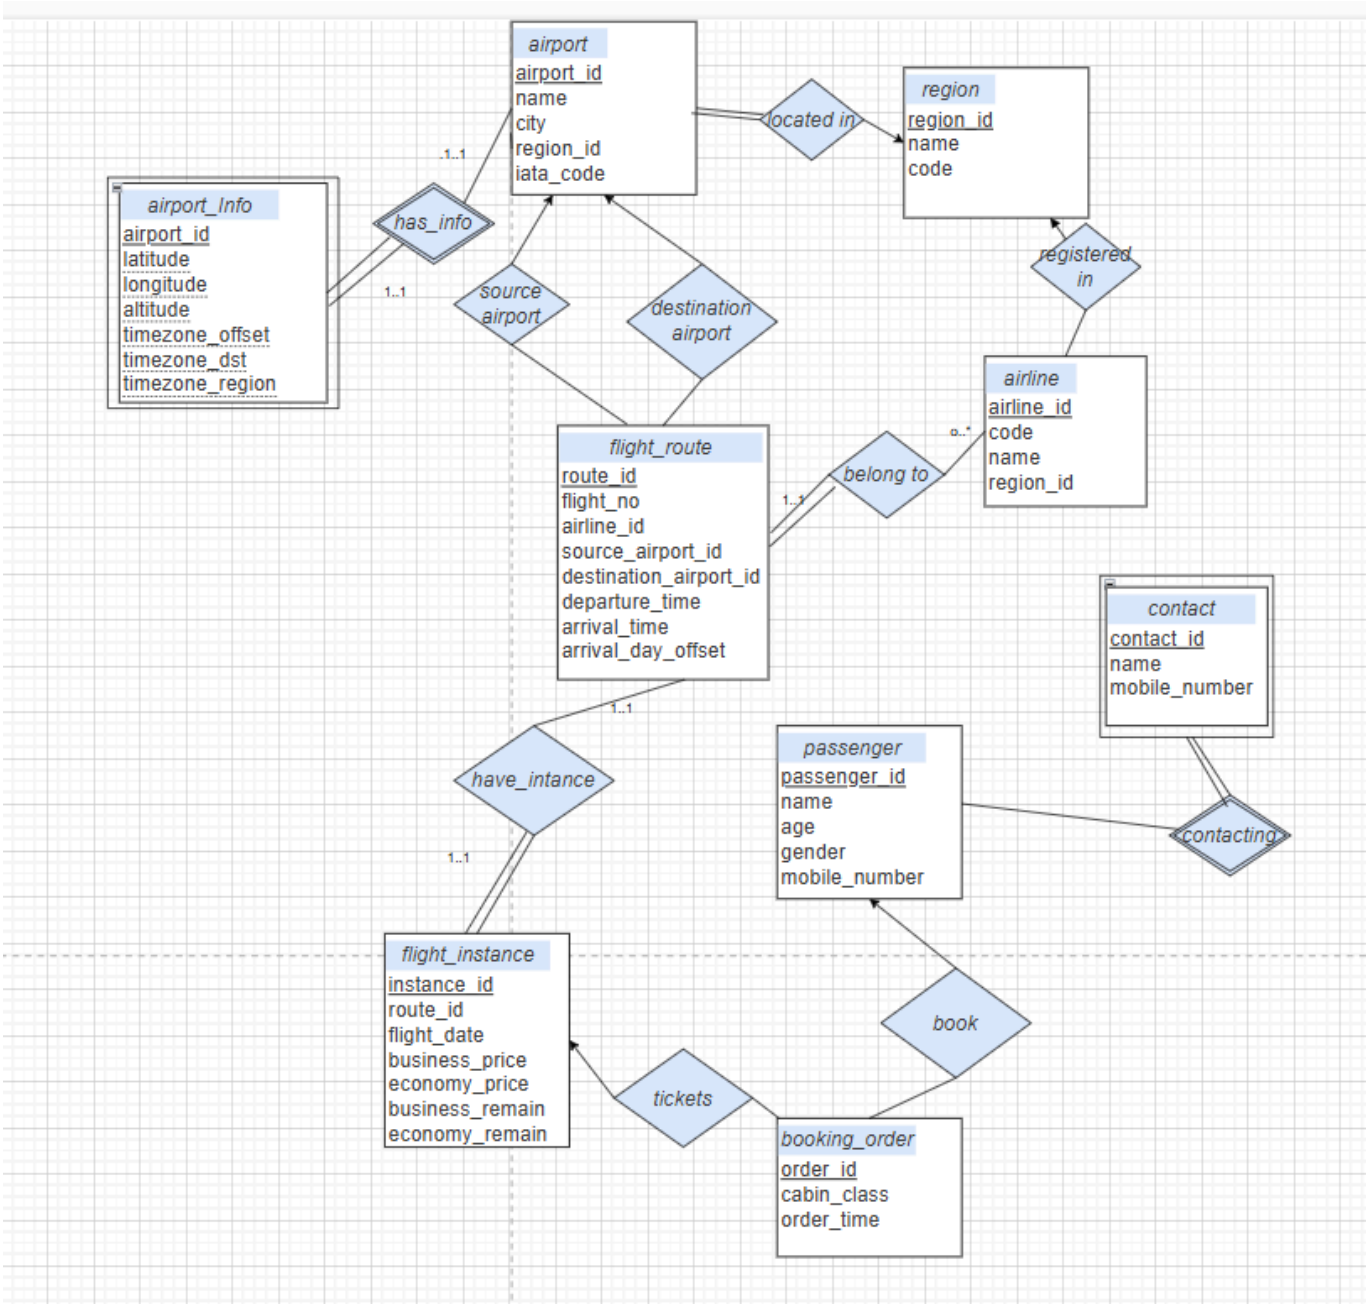

3.3 Task1 设计说明

主要实体与关系如下：

- region 与 airport：一对多（地区包含多个机场）
- region 与 airline：一对多（地区包含多个航司）
- airline 与 flight_route：一对多
- airport 与 flight_route：作为 source_airport 与 destination_airport 两种角色
- flight_route 与 flight_instance：一对多（静态路线到每日实例）
- airport 与 airport_info：一对一（扩展信息拆表）

四、Task2：数据库设计与 DDL（20%）

4.1 DataGrip 可视化 ER 图

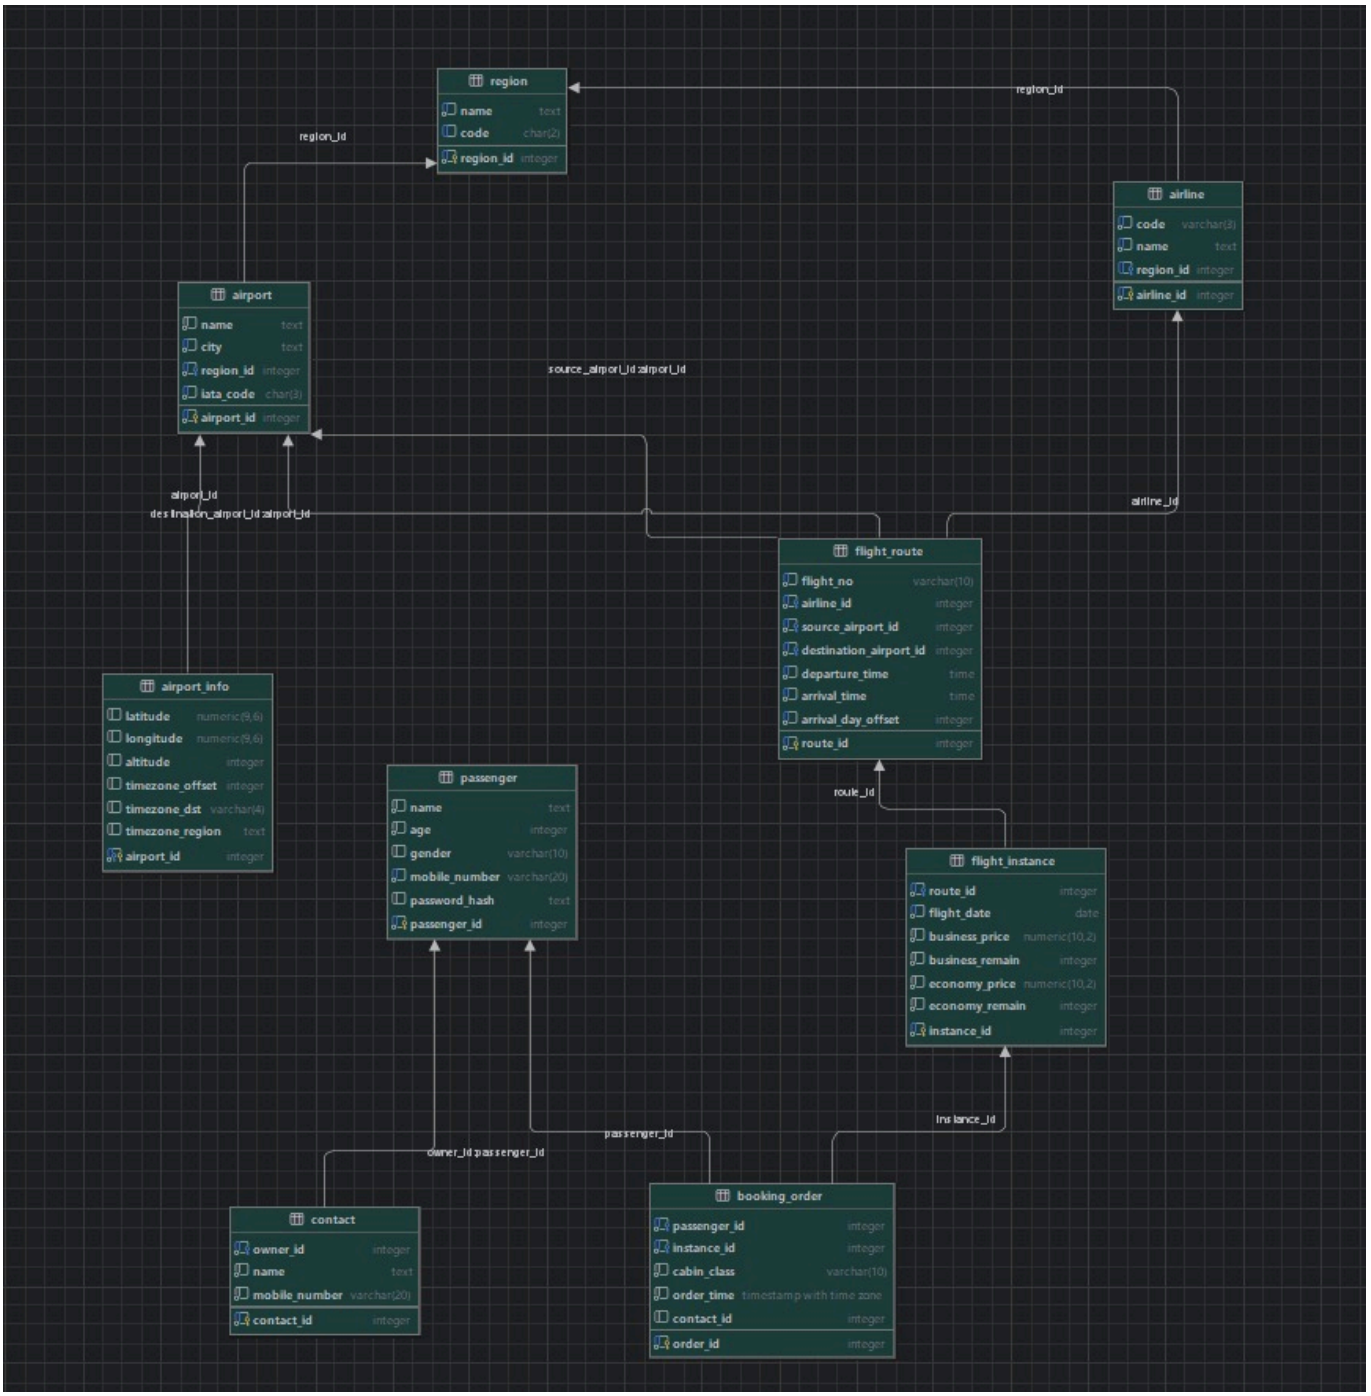

4.2 关系模型与表设计说明

本项目最终核心表如下：

- `region`：地区维表（`region_id`, `name`, `code`）
- `airline`：航司维表（含 `region_id` 外键）
- `airport`：机场核心表（含 `region_id`、`iata_code`）
- `airport_info`：机场扩展表（地理坐标、时区等）
- `passenger`：乘客信息表
- `flight_route`：静态航线表
- `flight_instance`：航班实例表（日期、舱位价格、余票）

对应 DDL 文件：`01_create_schema.sql`。

4.3 关键约束与一致性设计

1. 主键约束：每张表均有主键。
2. 外键约束：
   - `airline.region_id -> region.region_id`
   - `airport.region_id -> region.region_id`
   - `airport_info.airport_id -> airport.airport_id`
   - `flight_route.airline_id/source_airport_id/destination_airport_id`
   - `flight_instance.route_id -> flight_route.route_id`
3. 唯一约束：
   - `region.name`, `airline.code`, `airline.name`, `airport.iata_code`
   - `flight_route` 自然键组合唯一
   - `flight_instance(route_id, flight_date)` 唯一
4. 业务校验：
   - 地理坐标范围、时区范围
   - 舱位价格与余票非负
   - 出发与到达机场不能相同

4.4 规范化说明（1NF/2NF/3NF）

- 1NF：所有字段保持原子性。
- 2NF：将 `tickets.csv` 的静态/动态信息拆分，消除部分依赖。
- 3NF：地区与机场扩展信息拆分，减少传递依赖与冗余。

4.5 触发器与索引

`01_create_schema.sql` 中实现了：

- 触发器函数：`fn_normalize_region/airline/airport/passenger/route`
- 关键索引：`idx_airline_region_id`、`idx_airport_region_id`、`idx_route_search`、`idx_instance_query`

这些设计用于保证导入阶段的数据规范性与查询阶段的性能。

五、Task3.1：数据导入脚本与步骤（5%）

5.1 脚本清单

脚本名	作用
`import_csv_to_postgres.py`	读取 5 个 CSV，清洗并按依赖顺序导入 PostgreSQL
`generate_scaled_tickets.py`	生成扩容版 `tickets` 数据，用于 Task3.3 大数据实验

5.2 导入脚本核心能力

`import_csv_to_postgres.py` 主要功能：

1. 自动读取并解析 CSV。
2. 地区别名统一（如香港、韩国别名）。
3. 时间字段处理：`arrival_time` 的 `(+1)` 转 `arrival_day_offset`。
4. 拆分并导入 `flight_route` + `flight_instance`。
5. 自动补齐部分缺失机场代码（合成 IATA）。
6. 支持批量参数与分阶段计时输出（用于 Task3.3）。

六、Task3.2：数据准确性检查 SQL（15%）

以下 SQL 用于演示周现场验证，覆盖课程要求的 6 类查询。（附在01_create_schema.sql后面）

七、Task3.3：高级优化实验

根据项目时间与环境约束，本次重点完成两项高级要求：

- 要求 4：不同数据量导入实验
- 要求 5：提高导入效率（重点优化 `tickets` 导入）

7.1 实验环境

- 导入语言：Python 3
- 关键脚本：`import_csv_to_postgres.py`, `generate_scaled_tickets.py`

7.2 实验方法

1. 使用 `generate_scaled_tickets.py` 生成 `tickets_x5.csv`、`tickets_x10.csv`。
2. 通过 `--timing` 输出阶段耗时，重点观察 `insert_instance`。
3. 对比不同 `--page-size` 的总耗时与关键阶段耗时。

7.3 部分结果截图

- page-size=500：

```
PS D:\数据库原理\project1\cs307-project1> py import_csv_to_postgres.py --dbname postgres --schema public --user checker
--password 123456 --reset --timing --page-size 500 --tickets-file tickets_x5.csv
Import finished
Regions imported: 259
Airlines imported: 88
Airports imported: 207
Passengers imported: 1000
Routes imported: 21764
Flight instances imported: 544100
Synthetic airport codes added: MAC, JGS, LLB, YZY
Stage timings (seconds):
  - insert_airline: 0.004
  - insert_airport: 0.007
  - insert_airport_info: 0.004
  - insert_instance: 30.765
  - insert_passenger: 0.016
  - insert_region: 0.007
  - insert_route: 2.727
  - read_csv: 1.206
  - total: 45.823
```

- page-size=2000（tickets_x5）：

```
PS D:\数据库原理\project1\cs307-project1> py import_csv_to_postgres.py --dbname postgres --schema public --user checker
--password 123456 --reset --timing --page-size 2000 --tickets-file tickets_x10.csv
Import finished
Regions imported: 259
Airlines imported: 88
Airports imported: 207
Passengers imported: 1000
Routes imported: 21764
Flight instances imported: 1088200
Synthetic airport codes added: MAC, JGS, LLB, YZY
Stage timings (seconds):
  - insert_airline: 0.004
  - insert_airport: 0.007
  - insert_airport_info: 0.008
  - insert_instance: 46.513
  - insert_passenger: 0.016
  - insert_region: 0.008
  - insert_route: 2.765
  - read_csv: 2.416
  - total: 68.766
```

7.4 结果汇总

5. page-size 参数实验（同一数据量）

批量大小（page-size）	总耗时（秒）	关键阶段耗时（秒）
500	45.823	insert_instance: 30.765
2000	35.593	insert_instance: 26.366
5000	39.428	insert_instance: 26.261

6. 数据量扩容实验

数据倍数	总记录数	总耗时（秒）	关键阶段耗时（秒）
1 倍	108,820	5.204	read_csv: 0.245, insert_instance: 3.190
5 倍	544,100	35.593	read_csv: 1.222, insert_instance: 26.366
10 倍	1,088,200	68.766	read_csv: 2.416, insert_instance: 46.513

7.5 结果分析

1. page-size 从 500 提升到 2000，整体耗时下降明显（约 22.3%）。

2. page-size 继续增大到 5000，`insert_instance` 基本持平，但总耗时反而回升，说明过大批次引入额外开销。综合来看本电脑2000左右的 page-size 是较优选择。
3. 数据量从 1x 到 10x 时，总耗时总体呈近线性增长，说明脚本在大数据量下可稳定扩展。
4. 全流程瓶颈阶段始终是 `insert_instance`，后续进一步优化应优先针对该阶段。

八、结论与提交说明

8.1 Task1-Task3 完成情况

- Task1：完成（E-R 图已提供，工具与设计说明已给出）
- Task2：完成（DataGrip ER 图与 DDL 设计说明齐全）
- Task3.1：完成（导入脚本与执行步骤完整）
- Task3.2：完成（6 条检查 SQL 已准备）
- Task3.3：完成（不同数据量与导入效率实验及分析齐全）

8.2 附件对应关系

- Task1 图：`屏幕截图 2026-04-26 120102.png`
- Task2 DataGrip ER：`607881e8-3126-45dc-b592-4f0cd89a82d1.jpg`
- Task3.3 评测图：
  - `c2cf08b1-ef89-4c8d-8653-0402ff92375e.jpg`
  - `d3e51cd9-fdac-485a-81ed-83732acea52a.jpg`
  - `3719d376-93ed-40e6-bfe9-2285dac6e9d6.jpg`
- DDL 文件：`01_create_schema.sql`
- 导入脚本：`import_csv_to_postgres.py`
- 扩容脚本：`generate_scaled_tickets.py`